


PortFolio

진정_Portfolio_



Press START
to Continue



진정 Cedric

Email : wlswj010629@gmail.com

Phone : 010-9639-2847

Blog : <https://wlswj.github.io/>

Github : <https://github.com/wlswj>



학력 및 경력 사항

2024.11 - 2026.02

컴퓨터 공학 | 학사학위 취득 中 (現 100학점)

2020.08 - 2022.11

(주)제로웨이 기업부설연구소(전임 연구원)

2017.02 - 2020.02

포항제철 고등학교 | 입학 → 남산고등학교 | 졸업

2023.02 - 2024.08

육군과학화전투훈련단 | 병장 만기 전역

이수 교육

2025.11 - 2026.02

SK플래닛 T아카데미 | 관광 MICE 빅데이터 전문가 부산 17기

2025.03 - 2024.10

커널아카데미/업스테이지 | AI 부트캠프 137기

개발 스택



Python



SQL



Git



TypeScript



C++



Pandas



HuggingFace



Pytorch

유창한 영어회화

TOEIC 900+

기술 학습 기록



개인 블로그

꾸준한 실행력

습관은 기질을 압도한다

우수한 협업 커뮤니케이션



Slack



Confluence



Github

해외 거주 경험_

2007년부터 약 1년 반 동안 뉴질랜드의 Devonport Primary School을 다니며, 낯선 환경에 완전히 몰입하는 경험을 했습니다. 당시 어학연수 목적이 아닌 부친의 업무로 인한 거주였기에, 저는 별도의 어학 과정 없이 현지 아이들과 똑같은 환경에 던져졌습니다. 교과서의 문법 규칙을 암기하는 대신, 운동장에서 친구들과 소통하고 생존하기 위해 몸으로 언어를 배웠습니다.

이 시기에 형성된 '언어적 직관'은 제게 큰 자산이 되었습니다. 성인이 된 지금도 영어를 사용할 때 주어와 동사의 관계를 머릿속으로 계산하지 않습니다. 우리말을 하듯 자연스러운 흐름을 감각적으로 선택하게 되었고, 덕분에 별도의 시험 준비 없이도 영어 문장을 빠르고 정확하게 이해하는 능력을 갖추게 되었습니다. 이는 단순히 회화를 잘한다는 것을 넘어, 텍스트의 맥락을 파악하는 문해력의 기반이 되었습니다. 저는 어릴 적 체득한 영어에 대한 두려움 없는 태도 덕분에 기술 블로그를 원문 그대로 읽고 이해하는 데 강점이 있으며, 새로운 환경과 새로운 사람들과 일하는데 어려움 없이 시작할 수 있습니다!

습관은 기질을 압도한다_

좌우명

저는 타고난 재능보다 꾸준히 반복하는 습관이 결과를 만든다고 생각합니다.

새로운 기술을 배울 때도 한 번에 완벽히 이해하려 하기보다, 먼저 작게 실행하고 기록하며 개선하는 방식을 선호합니다.

학습 과정과 프로젝트 경험은 개인 블로그와 GitHub에 정리하고, 팀 프로젝트에서는 회의 내용과 작업 과정을 문서화하며 협업의 흐름이 끊기지 않도록 노력했습니다. 지금도 개인적으로 공부를 하면서 매일매일 한 것들을 시트에 정리하고, 정해진 스케줄대로 공부를 해나가고 있습니다.

또한 모르는 부분을 숨기기보다 빠르게 질문하고, 받은 피드백을 반영해 결과물을 개선하는 태도를 중요하게 생각합니다. 밝고 긍정적인 태도로 팀원들과 소통하되, 근거와 기록을 남기는 방식으로 신뢰를 쌓는 것이 제가 일하는 방식입니다.

A) 국가사업 R&D 진행

국토부 R&D

지자체 축제 분석

중기부 R&D

(국토부 R&D) IoT 센서 데이터 수집, 무결성 검증

P. 5

- LoRa 기반 유무선 실시간 people counting 센서 개발 지원
- Wi-Fi probe, IR-UWB 융복합 적용 알고리즘 개발 지원
- 다중 센서 데이터 결합 & 현장 실측 및 분석값 비교 분석

지자체 축제 방문객 데이터 분석 및 리포팅

- 합평 나비축제 방문객 데이터 수집 및 분석 후 보고서 작성
- 분석 데이터 기반 지자체 SNS 활용 마케팅 전략 수립 및 진행

(중기부 R&D) 스마트시티 플랫폼 기획 및 TTA 인증

- one2M TTA 표준 유동인구 플랫폼 기획 및 개발
- 센서 데이터 수집&저장 → 데이터 API 적합성 검토
- 지자체&공공기관 데이터 전달 및 활용방안 기획 후 전달

B) 부트캠프 경진대회 & Project

실거래가
예측 ML

문서타입
분류 CV

상품 구매
Recsys

IR/RAG
검색 PR

서울시 부동산 실거래가 예측 ML 경진대회 (3등)

P. 6

- 데이터 EDA & 이상치 탐색 및 파생변서 적용
- 회귀 모델(Randomforest, XGBoost) 비교 및 앙상블 적용

문서타입 분류 Computer Vision 경진대회 (4등)

- 이미지 데이터 전처리 및 증강(Augmentation) 전략 설계
- CNN 기반(resNet, EfficientNet) 모델 fine-tuning

커머스 상품 구매 예측 Recsys 경진대회 (1등)

P. 7

- 고객 구매이력, 관심사, 행동 로그 기반 추천 피쳐 엔지니어링
- 협업 필터링 및 모델(lightGBM, Matrix Factorization) 결합
- 랭킹 기반 추천 전략 설계 및 NDGC@10 기준 성능 최적화

IR/RAG 검색 성능 개선 프로젝트

P. 8

- 문서 검색 기반 Retrieval 파이프라인 개선
- BM25 / Dense Retrieval / Hybrid Search 실험
- Cross-Encoder Reranker 적용 및 결과 후처리

C) 개인 개발 사이드 Project

유튜브 채널 분석
리포트 및 RAG

게임 위키
RAG AI

게임 시스템
기획안(demo)

유튜브 채널 분석 리포트 작성 + 전용 RAG 개발

P. 9

- 영상 정보(제목, 조회수, 좋아요수, 댓글 등) YT-dlp 크롤링
- 영상 데이터 분석 후 채널 상태 및 성장 진행 방향 예측 분석
- 유튜브 영상 찾기 및 데이터 기반 채널 상태 분석 RAG AI 개발

게임 정보(인게임, 공략 등) 가이드 RAG 개발

P. 10

- 마인크래프트 & 발해임 위키 기반 인게임 정보 전부 수집
- chromaDB 활용 데이터 임베딩 후 저장 → 이용자가 게임 공략 혹은 인게임 정보 질의 시 수집 데이터 기반 답변
- 질의 답변 수준 증강을 위한 prompt-engineering 진행

게임 시나리오 및 시스템 기획안 작성(demo 개발중)

- 스테이지 기반 리듬 게임 스토리 작성
- 인게임 시스템(맵, 전투, 상호작용 등) 구현 방법 설계
- (개발중) 15분 가량 플레이 가능한 데모 ver. 개발 중

기본 정보

[기술] Python / Pandas / Scikit-learn / LightGBM / XGBoost / AutoGluon

[기간] 2025.05 ~ 2025.06

[역할]

- EDA 및 데이터 전처리 (위경도 XY 수치 결측)
- 파생 변수 생성 및 모델 성능 개선 (역세권 등 공공api 활용)
- 모델 학습 / 검증 / 제출 결과 비교

결과 및 성과물

경진대회 순위

3등

최종 RMSE

11491.4377



▲ 당시 발표자료

순위	팀이름	팀멤버	RMSE	제출횟수	최종 제출
내등수 3	ML_9조	정민, 진혁, J	11491.4377	35	11M
1	ML_5 조	박기, 상민, 김우, 윤서	10463.6480	67	11M
2	ML_4조 조	홍민, 배민, 상민	11412.4438	56	11M
3	ML_9조 조	정민, 진혁, J	11491.4377	35	11M

▲ 경진대회 리더보드

과정 및 주요 활동 요약

서울시 아파트 실거래가 데이터를 기반으로 부동산 거래금액을 예측하는 회귀 모델을 개발했습니다.

단순히 모델을 학습시키는 것보다, 가격에 영향을 주는 지역, 면적, 층수, 건축년도, 거래 시점 등의 변수를 분석하고, 결측치·이상치·왜도 분포·다중공선성 문제를 처리하는 데 집중하였습니다.

특히 한강 거리, 지하철역/버스정류장 정보, 지역 및 평형 클러스터링, 신축 여부, 면적대 구간, 층수 범주화 등의 파생 변수를 생성하여 모델이 부동산 가격의 공간적·구조적 특성을 학습할 수 있도록 하였습니다.

모델링 단계에서는 베이스라인 체크 후 비교적 초기부터 AutoML 중 autogluon 프레임워크를 활용함 (autogluon: torch nn, lgbm, cat, xgb 모델 조합과 스택킹, 배깅, 앙상블 조합 공간 서치 + valid 셋 분류 자동화 & KFold 및 stratifiedKFold의 cv를 활용하여 valid 셋에 대한 rmse 확인)

인사이트 1

원본 데이터의 중요성

Feature Engineering의 실패를 통해, 원본 데이터 자체에 이미 예측에 필요한 충분하고 중요한 정보가 내포되어 있을 가능성에 주목하게 됨

제공된 아파트 실거래가 데이터는 가격 결정에 핵심적인 Feature들을 포함하고 있으며, 모델이 이러한 기본적인 정보를 효과적으로 학습하는 것이 중요한 것을 알게됨

인사이트 2

학습 / 검증 / 제출 결과 비교

예상과는 달리, 지하철 및 버스정류장과 거리 등 외부 정보를 활용한 다양한 Feature Engineering 시도는 데이터의 노이즈를 증폭시켜 예측 성능을 저하시키는 경향을 보였습니다.

무조건적으로 많은 Feature를 생성하는 것이 좋지 않으며, 데이터의 특성과 모델의 복잡성을 고려한 신중한 Feature Engineering이 필요함을 깨달음.



▲ 코드 작업물(일부)

기본 정보

[기술] Python / Pandas / PyTorch / RecBole / SASRec / ALS / RRF

[기간] 2025.09 ~ 2025.10

[역할]

- 사용자 행동 로그 기반 추천 모델링 + EDA 및 데이터 전처리
- ALS / SASRec 모델 학습 및 추론
- RRF 기반 앙상블 및 Top-K 추천 성능 개선

과정 및 주요 활동 요약

온라인 스토어의 사용자 행동 로그를 활용해 사용자별 Top-K 상품 추천 모델을 개발했습니다. view, cart, purchase 이벤트를 기반으로 사용자-아이템 상호작용 데이터를 구성하고, 시간 순서, 최근성, 이벤트 중요도를 반영한 전처리를 수행했습니다.

모델링 단계에서는 implicit feedback 기반 ALS와 순차 추천 모델 SASRec을 구축했습니다. ALS는 전역적인 사용자-아이템 잠재 패턴을 학습하는 데 활용했고, SASRec은 사용자의 최근 행동 흐름과 순차적 구매 패턴을 반영하는 데 사용했습니다.

최종적으로 RRF 기반 앙상블과 브랜드/카테고리 일지 보너스 → co-visitation 기반 재랭킹을 적용하여 추천 성능을 개선했습니다. 그 결과 NDCG@10 0.1154를 기록하며 최종 리더보드 1위를 달성했습니다.

결과 및 성과물

경진대회 순위

1등

NDCG@10

0.1154



▲ 당시 발표자료

순위	팀이름	팀멤버	NDCG@10	제출횟수	최종 제출
내등수 1	Recsys 3조	J 재용 W	0.1153	31	6M
1	Recsys 3조	J 재용 W	0.1153	31	6M
2	Recsys 5조	성진	0.1077	30	6M

▲ 경진대회 리더보드

모델링 과정

1) **ALS (Alternating Least Square)** : 기본 모델로 ALS를 적용하여 NDCG@10 지표를 기준으로 성능을 평가하였으며, 하이퍼파라미터 튜닝 (정규화, 알파, epoch, 잠재 차원 조정)을 통해 기존 베이스라인 대비 약 13% 상승하는 성과를 확인 (factors=32, alpha=10, reg=0.001 → submission_als.csv)

2) **SasRec (Self-Attentive Sequential Recommendation)** : SasRec은 사용자의 아이템 상호작용 순서를 고려하는 모델로, 시계열 데이터를 활용하여 추천의 정확도 향상. 단점으로는 학습 시간이 오래 걸리는 점이 있으나, 최소 상호작용 횟수를 조정하는 등의 방법으로 성능 최적화 시도

결론 : ALS + SasRec 앙상블

ALS는 전역 잠재요인과 공출현 패턴에 강해 상호작용이 적은 (콜드/라이트) 사용자에서 견고하고, SASRec은 시퀀스·최근성 신호를 학습해 상호작용이 많은(월/핫) 사용자에서 정밀도가 높음. 즉, 두 모델의 강점을 사용자 활동량별로 가변 가중으로 결합해 NDCG@10을 끌어올리도록 함

기본 정보

[기술] Python / Elasticsearch / BM25 / FAISS / RRF / Cross-Encoder

[기간] 2025.08 ~ 2025.09

[역할]

- BM25 / Dense Retrieval / Hybrid Search 실험
- Chunking, RRF, Candidate 수 조정 등 검색 성능 튜닝
- Cross-Encoder Reranker 적용 및 결과 후처리

과정 및 주요 활동 요약

문서 집합에서 사용자 질의와 가장 관련도 높은 문서 ID를 반환하는 검색 기반 Retrieval 모델을 개선했습니다.

초기 Baseline은 BM25와 Dense Retrieval 기반의 Hybrid Search 구조였으며, 문서 길이 차이와 검색 단위 문제를 해결하기 위해 window/stride 기반 Chunking 전략을 적용했습니다.

Sparse Retrieval에서는 Kiwi tokenizer 기반 BM25를 활용했고, Dense Retrieval에서는 SBERT 계열 임베딩과 FAISS 인덱스를 사용해 의미 기반 검색 성능을 보완했습니다.

이후 BM25 + Dense 결과를 RRF 방식으로 결합하고, 상위 후보군에 Cross-Encoder Reranker를 적용하여 Recall과 Precision의 균형을 개선했습니다.

추가로 query별 예외 처리, doc_id 중복 제거, candidate 수 조정, chunk 크기 튜닝을 반복하며 최종 검색 성능을 높였습니다.

결과 및 성과물

Rouge_result

45.6567



▲ 당시 발표자료

팀이름	팀멤버	rouge1	rouge2	rougeL	final_result
NLP_8조		0.5548	0.3457	0.4692	45.6567

▲ Rouge 점수

최종 모델링 채택

1) 두 개의 FAISS 인덱스 사용

faiss_index_question(retriever1) - (LLM으로 생성시킨 document vectorstore)

faiss_index_KURE-v1_semantic(retriever2) - (제공받은 document vectorstore)

→ 같은 임베딩 모델(nlpai-lab/KURE-v1)로 인덱싱했지만, 상이한 인덱스/데이터 구성을 병렬로 조회해 보완적 후보를 확보

2) Dense 앙상블(Ensemble Retriever)

retrievers=[retriever1, retriever2], weights=[0.1, 0.9]

→ 두 Dense 결과를 가중합으로 스코어 결합(랭체인 표준).

→ recall(후보 다양성)과 일관성(semantic 인덱스 비중↑)을 동시에 확보.

Project Detail 5 - 유튜브 채널 분석 리포트 작성 + 전용 RAG 개발_

09

기본 정보

[기술] Python / YouTube Data API / HuggingFace / Streamlit / RAGAS

[기간] 2026.03 ~ 2026.04

[역할]

- 유튜브 데이터 수집 파이프라인 설계(임베딩 후 Vector DB 저장)
- 청크 & 검색 로직 구현 → RAGAS 기반 자체 평가 후 개선점 분석
- 웹화면(streamlit) UI 개발 후 배포 진행

결과 및 성과물

RAGAS 자체평가
(faithfulness)

0.8561




▲ RAG 웹사이트 화면(streamlit 배포)

기획 의도 및 개발 요약

평소 즐겨 보던 유튜브 채널의 콘텐츠 흐름과 시청자 반응을 정량적으로 분석해보고자 직접 설계·구현한 채널 전용 RAG 파이프라인입니다. 영상 메타데이터와 자막 텍스트를 통합 분석할 수 있는 도구를 목표로 했습니다.

수집 단계에서는 YouTube Data API로 채널 업로드 목록과 영상 메타(조회수·업로드 시점·제목)를 확보하고, 자막은 youtube_transcript_api로 1차 수집 후 누락·실패분만 yt-dlp로 재수집하는 풀백 구조를 구성해 데이터 결손을 최소화했습니다. 수집된 원본은 채널별 Raw JSON으로 보관하고, 별도 청크 스크립트로 검색에 적합한 길이로 정제해 JSONL 포맷에 분리 저장함으로써 원본 보존과 재청크 작업이 독립적으로 가능하도록 설계했습니다.

검색·분석 레이어는 Streamlit 기반 채팅 UI로 구현해 사이드바 채널 토글, 키워드 부분 문자열 매칭, 발췌·링크 표시, 월별 업로드·조회수 통계 패널을 제공하며, 항후 임베딩·벡터 스토어(Chroma/FAISS) 확장을 염두에 두고 청크와 검색을 모듈로 분리해 설계했습니다.



◀ 자체 제작 유튜브 채널 분석 보고서

기본 정보

[기술] Python / YouTube Data API / HuggingFace / Streamlit / RAGAS

[기간] 2026.03 ~ 2026.04

[역할]


- 유튜브 데이터 수집 파이프라인 설계(임베딩 후 Vector DB 저장)
- 청크 & 검색 로직 구현 → RAGAS 기반 자체 평가 후 개선점 분석
- 웹화면(streamlit) UI 개발 후 배포 진행

결과 및 성과물



RAGAS 자체평가
(faithfulness)

0.8721



▲ RAG 웹사이트 화면(streamlit 배포)

기획 의도 및 개발 요약

평소 즐겨하던 Minecraft와 Valheim 게임 플레이에 필요한 정보가 공식 위키, 커뮤니티 위키, 영상 등에 흩어져 있어 통합적으로 질의·검색하기 어렵다는 문제에서 출발한 RAG 기반 도메인 특화 챗봇입니다. 한국어 사용자를 대상으로 공식 정보와 커뮤니티 노하우를 한 번에 제공하는 것을 목표로 했습니다.


데이터 수집은 두 갈래로 분리해 구성했습니다. 공식 위키는 MediaWiki API를 통해 아이템·몹·구조물·명령어 등 약 800개 문서를 일괄 크롤링했고, 나무위키는 BeautifulSoup4 기반 심층 크롤링(Deep Crawl)으로 약 2,200건의 탐·글리치 데이터를 추가 확보했습니다. 수집 진행 상황은 별도 처리 이력 파일로 관리해 중단 후 이어받기가 가능하도록 설계했습니다.

수집된 문서는 청크 단위로 분할 후 한국어 특화 임베딩 모델(ko-sroberta-multitask)로 벡터화해 ChromaDB에 적재했습니다. 검색·응답 단계는 LangChain의 History-Aware Retrieval로 대화 문맥을 유지하고, Google Gemini 2.5 Flash와 연동해 Streamlit에서 실시간 스트리밍으로 답변을 출력하도록 구현했습니다.



▲ 적용된 게임

(좌:마인크래프트 / 우:발헤임)



▲ 데이터 수집 웹사이트 (출처: 공식 위키)

The End

Thanks
For
Watching